

2026 KAIST AI x 실패 아이디어 공모전

팀 리볼빙 (이준엽, 조기원)

1단계. 예견된 실패

2036년 교육의 가장 큰 실패는 학생들의 판단 능력이 약해졌음에도 학교가 이를 실패로 인식하지 못한다는 데 있습니다. 학업 성취도, 진학률, 취업률, 학생 만족도와 같은 공식 지표는 계속 상승합니다. 그러나 학생이 스스로 문제를 발견하고, 여러 가치가 충돌하는 상황에서 우선순위를 정하며, 자신의 결정에 책임지는 능력은 평가 대상에서 빠져 있습니다. 학교는 AI의 도움으로 향상된 결과물을 교육의 성공으로 판단하고, 그 성과를 기준으로 교육과정과 평가 제도를 다시 설계합니다.

2027년부터 교육청 인증 AI 튜터가 학생의 지식, 관심, 감정과 수행 기록을 하나의 장기 프로필로 관리하기 시작했습니다. 2030년 무렵에는 지필시험의 의미가 약해지고, 학생이 모든 사고 과정을 직접 수행하는 것보다 에이전트에게 목표·예산·제약 조건을 설정하고 결과를 승인하는 능력이 중요해졌습니다. 2032년 이후에는 에이전트 간 위임망이 더욱 복잡해졌습니다. 하나의 과제를 수행하기 위해 여러 모델과 하위 에이전트, 외부 서비스와 물리적 장치가 연결되면서 누가 어떤 판단을 내렸는지를 완전히 추적하기 어려워졌습니다. 2033년에는 교육환경에서도 피지컬 AI를 통해 에이전트가 실습과제를 대행하는 일이 일반화되었고, 학교는 이에 대응해 결과물 대신 프롬프트 기록, 반박 횟수, 메타인지 로그와 에이전트 조정 능력을 평가하기 시작했습니다.

2034년 이후 평가는 학생 개인의 지식보다 학생이 구성한 인간-에이전트 시스템의 성과를 측정하는 방향으로 이동했습니다. 어떤 모델을 사용하는지에 따라라도 성취도 측면에서 큰 차이를 보이게 되었습니다. 2035년 일부 지자체에서는 정기 지필시험이 사라지고, 평가가 프로젝트 성과, 행동 로그, 포트폴리오와 사회적 평판으로 대체되었습니다. 학생이 직접 판단했는지를 확인하는 무도구 검증은 형평성과 접근성 문제로 의료·안전·법률 등 일부 분야에만 남았습니다. 그 결과 2036년의 학교는 높은 성과를 유지하면서도, 학생이 자신의 옳고 모름을 구분하고, 불완전한 정보 속에서 첫 질문을 만들며, 가치가 충돌하는 상황에서 스스로 결정하도록 훈련하는 기능을 점차 잃어가고 있었습니다.

2036년의 AI는 단순한 보조 도구가 아니라 학습의 목표와 경로를 제시하는 핵심 환경이 되었습니다. 개인 학습 에이전트는 학생의 행동과 학습 상태를 분석해 다음에 읽을 자료, 물어볼 질문, 선택할 과목과 해결 방법까지 추천합니다. 학생들은 복잡한 자료를 빠르게 정리하고 완성도 높은 보고서와 발표물을 만들지만, AI 도입 이후 인간은 이해할 수 없는 복잡해진 문제들이 만연해지면서, 학생들은 무엇을 먼저 해결해야 하는지, 누구의 이익을 우선해야 하는지, 어떤 손실을 감수할 것인지처럼 정답이 없는 문제에서는 AI의 도움 없이는 목표 설정과 질문 생성, 우선순위 판단 등을 하지 못하게 되었습니다.

2단계. 원인 진단

실패 축	2026년에 이미 보인 신호	놓친 선택과 2036년의 결과
① 사고의 외주화	MIT Media Lab(2025)은 54명의 에세이 작성 실험에서 LLM 집단의 뇌 연결성이 가장 약하고, 자기 글 회상·소유감도 낮았다고 보고했습니다. Gerlich(2025)의 666명 조사에서도 AI 사용과 비판적 사고의 음의 상관을 인지 오프로딩이 매개함을 도출했습니다.	학교는 도구 호출·승인 로그를 남겼지만 누가 문제와 기준을 정했는지는 묻지 않았다. 2032년 학생은 완료율이 낮아진다는 경고에 자신의 선택을 포기했고, 2036년에는 에이전트가 질문 후보를 제시해야 프로젝트가 다시 움직였다.
② 인지 격차	국민일보(2026)는 교육·소득이 높은 집단일수록 AI 정보를 이해하고 신뢰성을 판단한다고 보도했습니다. Puri & Veldkamp(2026)는 AI를 활용하는 능력의 차이가 생산성 격차를 넘어 인지 능력 자체의 불평등으로 누적될 수 있음을 분석했습니다.	AI 접근 확대로 교육 격차는 일부 줄었지만, 독립 판단을 검증하는 기회는 보편화되지 못했다. 2034년 무도구 구술평가는 장애·언어 배경에 불리했고 사교육 대비 격차까지 날아 5% 무작위 감사로 축소됐다. 형평성을 지키려다 판단 역량을 깊게 볼 기회가 사라졌다.
③ 평가의 오독	Inside Higher Ed(2025)는 AI 대필 우려로 미국 대학에서 손글씨 과제와 블루북 시험이 되살아났다고 보도했습니다. Brown대 강의에서는 AI 사용 의심을 받은 재택 중간고사 평균 96점이 감독형 대면 기말에서 48점으로 낮아지며, 인간 평가 시스템의 붕괴를 시사하고 있습니다. (IBTimes 2026).	학교는 자동평가에 반례·위험·메타인지 기록을 추가했지만 에이전트도 곧 그 기준에 적응했다. 2036년에는 최초 질문과 AI 반박 횟수까지 다시 지표화되어 점수만 회복됐다. 평가는 정교해졌지만 질문이 학생에게서 나왔는지 증명할 수 없었다.

3단계. 대응 방안

저희는 앞서 예견한 세 실패가 공유하는 뿌리, 곧 AI의 파급효과를 이해하고 다룰 역량의 공백에 대한 대응으로, AI literacy를 개념과 대상 두 축으로 확장할 것을 제안합니다. 개념적으로는 AI literacy를 산출물을 다루는 기능적 역량을 넘어 자신의 앎과 모름을 확인하고 AI의 장기 파급효과를 예견하는 메타인지로 확장합니다. 대상적으로는 이 역량을 기술을 소비하는 사용자에게 한정하지 않고 AI를 설계하는 공급자와 정책을 수립하는 의사결정자에게로 넓히되, 각 주체에 맞게 워크플로우에 적용 및 제도화합니다. 저희는 이 과정을 뒷받침하는 도구로 Unknown Compass를 제시하며, 궁극적으로 생태계 구성원이 AI의 위험을 스스로 인지하고 예방하도록 하는 것을 목표로 합니다.

(1) 개념적 확장 — literacy를 메타인지로.

개념적 확장이란 AI literacy를 ‘산출물을 소비하는 기능’에서 ‘자신의 앎과 모름을 인식하는 메타인지(Flavell, 1979)’로 재정의하는 것입니다. 사람은 스스로 모른다는 사실조차 모르는 상태(unknown unknowns)에 취약합니다(Kruger & Dunning, 1999). 저희가 제시하는 도구 Unknown Compass는 사용자의 지시(prompting)를 아는 것과 모르는 것의 4분면으로 시각화하여, 답을 대신 제시하지 않고 사용자가 그 공백을 스스로 메우도록 합니다. 이는 근접발달영역(Vygotsky, 1978)을 이어주는 메타인지적 비계(Wood, Bruner, & Ross, 1976)로 기능합니다. 즉, 오프로딩으로 인한 사고 저하를 공백의 인식을 통한 비판적 사고로 역전시킬 것입니다.

(2) 대상적 확장 — literacy를 이해관계자 전체로.

개인이 메타인지를 갖추는 것만으로는 나머지 세 실패에 닿을 수 없습니다. 격차와 교사의 붕괴, 평가의 무력화는 개인이 아니라 시스템과 정책의 총위에서 발생하는 구조적 실패이기 때문입니다. 공교육은 literacy 역량을 무상 공공재로 제공해 소득·장애·언어 배경의 격차 없이 최소 검증 역량을 보장해야 합니다. 학교는 산출물·로그의 양이 아니라 AI 도움을 단계적으로 줄인 뒤에도 남는 지속 가능한 역량(durable capability)을 표본 구술·과정 관찰·설명으로 확인해야 합니다(Yan 2026). 공급자와 정책 결정자는 시스템·정책 도입 전에 기대효과뿐 아니라 장기 파급효과를 서술하고 검증해야 합니다.

이 대응들을 가능하게 하는 것은 제도화입니다. 현재 EU AI Act(Reg. 2024/1689)는 학습성과 평가·교육 접근을 결정하는 AI를 고위험으로 분류하고 기술문서·적합성 평가·기본권 영향평가 장치를 두고 있습니다. 국내에도 '학생 1인 1 AI 튜터'(대전시교육청, 2026) 같은 보편 배포가 현실화되는 만큼, 이 선례를 들여오되 검증 항목을 한 가지 넓히자고 제안합니다. 바로 기술적 정확성·안전뿐 아니라 설계자가 장기 파급효과를 충분히 예견했는지, 곧 설계자의 리터러시를 함께 확인하도록 하는 것입니다.

실행 로드맵

주체	조치 (무엇을)	시점
교육부·시도교육청	메타인지 literacy(앎/모름을 시각화하는 Unknown Compass 등)를 공교육 정규 과정에 편입하고 계층과 무관하게 보편 배포	~2028 시범 ~2031 전면
AI 정책 부처 (과기정통부 등)	교육 AI에 대해 ‘기대효과 사전 서술 + 관리자 검증’을 의무화하는 입법 (EU AI Act 선례 국내 이식; 대전시교육청 정책 사례 참고)	~2029
교육 AI 공급자	배포 전 파급효과(고립·편향·진로 오판·격차) 영향을 서술하고 공개	즉시~2027
학교·교사	평가 대상을 산출물에서 과정(prompting 기록·메타인지 상태 변화) 중심으로 전환	~2028 파일럿

이처럼 개념과 대상 두 축의 확장은 개인의 사고와 사회의 시스템을 동시에 지탱하며, 앞서 예견한 세 실패에 실효성 있게 대응하는 길이 됩니다. 무엇보다 이 대응은 특정 모델이나 기술 세대가 아닌 AI 그 자체에 대한 이해에 기반하기에, AI의 미래 방향성과 무관하게 유효합니다.